



تحلیل داده‌های حجیم


دکتر محمد علی نعمت‌بخش
طراح : علی معینیان

پروژه 1: Kafka - تئوری و مفاهیم (30 امتیاز)

در این بخش باید با جستجو در مستندات رسمی و مقالات معتبر و به کمک AI به سوالات زیر پاسخ دهید.

یک: توضیح دهید کافکا چیست؟ چه مشکلاتی را حل می‌کند؟ مشکل سیستم‌های پیام‌رسانی سنتی در مقیاس بزرگ چه بوده است؟ حتماً با جستجو در اینترنت یک مثال واقعی صنعتی بیاورید.

دو: معماری کلی کافکا را به توضیح دهید.



سه: مفاهیم Replication و Fault Tolreance در کافکا چه هستند و چگونه کار می‌کنند؟

منابع پیشنهادی جهت مطالعه :

<https://kafka.apache.org/23/streams/architecture/>

<https://www.geeksforgeeks.org/apache-kafka/kafka-architecture/>



تحلیل داده‌های حجیم

دکتر محمد علی نعمت‌بخش
طراح : علی معینیان

پروژه 1: Kafka - قسمت عملی (60 امتیاز)

برای راه اندازی کافکا پیشنهاد می‌کنم از Docker استفاده کنید. استفاده از Docker یک استاندارد در صنعت است و شما را از درگیری با تنظیمات پیچیده سیستم عامل بی‌نیاز می‌سازد. البته، استفاده از Docker صرفاً پیشنهاد است. در تمرین‌های بعدی شاید لازم باشد بدون Docker یک Pipe Line کامل طراحی کنید.

شما باید یک Kafka Cluster که در این تمرین به صورت Single-Node شامل یک Broker است راه اندازی کنید که وظیفه‌ی پردازش جریان Clickstream را بر عهده دارد.

برای تولید 100 پیام نمونه، می‌توانید از LLM استفاده کنید. ساختار دقیق داده‌ها در قالب JSON و به نام events.json باید به این شکل باشد :

```
{
  "event_id": string
  "timestamp": ISO-8601 string
  "user_id": integer between 1 - 5000
  "event_type": [ page_view, button_click, add_to_cart, purchase, login ] یکی از این 5 تا باید باشد
  "page_url": string [/home, /product/456, /checkout, /category/mobile] مشابه مثال های زده شده
  "session_id": string
  "value": فقط اگر کاربر خرید کرده بود مقدار داشته باشد در غیر این صورت باید نال باشد
  "device_type": [mobile, desktop, tablet] یکی از این 3 تا باید باشد
  "location": یک شهر رندوم مانند اصفهان
}
```

با استفاده از Docker و فایل docker-compose.yml کافکا را راه اندازی کنید و آن را با دستور زیر اجرا کنید :

```
docker compose up -d
```

باید مشخص کنید که از kafka با KRaft mode استفاده می‌کنید یا خیر ؟ به انتخاب خودتان است. اگر از Docker استفاده نمی‌کنید، به طور عادی کافکا را نصب کنید و مراحل زیر را انجام دهید.

با توجه به اینکه در این تمرین کافکا به صورت Single-Node که شامل یک Broker است راه اندازی می‌شود، یک Topic با نام user-activity-stream با 4 پارتیشن ایجاد کنید. انتخاب چند پارتیشن صرفاً با هدف مشاهده نحوه توزیع پیام‌ها بین Consumer های یک Consumer Group و درک عملی مفهوم Parallel Consumption انجام می‌شود.

حال می‌توانید با kafka-console-consumer از ابتدا همه پیام‌ها را بخوانید.

یک اسکریپت پایتونی بنویسید که فایل events.json تولید شده را بخواند و هر رکورد را به صورت پیام به Topic ارسال کند.

یک Consumer Group به نام analytics-group بسازید و دو instance از Consumer هم زمان اجرا کنید. (در دو ترمینال)

باید مشاهده کنید که هر Consumer فقط پیام های مربوط به پارتیشن های خود را دریافت می‌نماید. در نهایت هر Consumer باید پیام های دریافتی خود را در فایل خروجی مجزا ذخیره کند.



تحلیل داده‌های حجیم

دکتر محمد علی نعمت‌بخش

طراح : علی معینیان

آنچه باید تحویل دهید (10 نمره)

- داکيومنت پاسخ های سوالات قسمت اول
- داکيومنت کامل پیاده سازی قسمت عملی به همراه تمام کدها و فایل JSON ساخته شده
- حتما از اجرای پروژه اسکرین شات بگیرید و در داکيومنت قرار بدهید.
- داکيومنت شما حتما باید منبع داشته باشد و منبع هم به صورت دقیق باید ذکر شود. همچنین در صورت استفاده از AI حتما ذکر کنید.
- فرمت ارسالی شما باید ZIP باشد و نام فایل باید از الگوی زیر پیروی کند :

BigData - HW1 - StudentName - StudentNumber

مثلا

BigData - HW1 - AliMoeinian - 65465684816

زمان تحویل : 15 اسفند
6 March