



دانشگاه اصفهان

درس تحلیل و سیستم‌های داده‌های حجیم

تمرینات فصل MapReduce: پیاده‌سازی با استفاده از پایتون

استاد: دکتر محمدعلی نعمت بخش

طراح تمرین: بهنوش بهیانی

مهلت ارسال: ۱۴۰۵/۰۲/۰۴

۱- مقدمه و هدف تمرین

هدف از این تمرین، آشنایی عملی با مدل پردازشی MapReduce و پیاده‌سازی آن با استفاده از کتابخانه mrjob در زبان پایتون است. در این تمرین، از شما انتظار می‌رود اطلاعات معناداری را از یک مجموعه داده بزرگ استخراج کنید و در نهایت یک سیستم پیشنهاددهنده^۱ ساده طراحی کنید.

۲- معرفی مجموعه داده

در این تمرین از مجموعه داده‌ی معروف MovieLens استفاده خواهیم کرد. این مجموعه شامل اطلاعات فیلم‌ها، امتیازات کاربران و برچسب‌های^۲ ثبت شده است.

❖ [لینک داخلی دریافت مجموعه داده](#)

فایل‌های اصلی که در این تمرین با آن‌ها سروکار دارید عبارتند از:

- movies.csv: شامل اطلاعات فیلم‌ها (شناسه، عنوان، ژانرها)
- ratings.csv: شامل امتیازات کاربران به فیلم‌ها
- tags.csv: شامل برچسب‌هایی که کاربران به فیلم‌ها اختصاص داده‌اند

پیشنهاد

شما می‌توانید ابتدا برای بررسی صحت عملکرد کدهای پیاده‌سازی شده از مجموعه داده نمونه که در ادامه لینک‌های دسترسی به آن قرار داده شده است استفاده کنید:

❖ [لینک اصلی دریافت داده نمونه](#)

❖ [لینک داخلی دریافت داده نمونه](#)

نکته

خروجی‌های نهایی شما فقط باید از داده‌های اصلی باشد و در صورت استفاده از داده نمونه نمره‌ای به تمرین شما تعلق نمی‌گیرد.

^۱ Recommender System

^۲ Tags

۳- شرح وظایف^۱

شما باید ۴ وظیفه زیر را با استفاده از کتابخانه mrjob پایتون پیاده‌سازی کنید.

۳-۱- وظیفه اول: تحلیل پایه امتیازات فیلم‌ها (Movie Ratings Profiling)

برنامه‌ای بنویسید که فایل امتیازات را پردازش کرده و برای هر فیلم، خروجی زیر را تولید کند:

۱. تعداد کل نظرات (امتیازات) ثبت شده.

۲. میانگین امتیازات^۲ محاسبه شده.

نکته ریاضی: میانگین امتیاز یک فیلم (μ) از رابطه $\mu = \frac{\sum_{i=1}^n r_i}{n}$ به دست می‌آید که در آن r_i امتیاز کاربر i و n تعداد کل نظرات است.

* خروجی:

فایل csv شامل ستون‌های شناسه یا نام فیلم، تعداد نظرات و میانگین امتیاز

TEXT		
movieID	total_ratings	avg_rating
1	973	3.54
2	527	3.17
...		

۳-۲- وظیفه دوم: استخراج برچسب‌های کلیدی (Top Tags Extraction)

با پردازش فایل برچسب‌ها، برای هر فیلم حداکثر ۴ برچسب^۳ که بیشترین تکرار را در میان کاربران داشته‌اند، پیدا کرده و نمایش دهید. در صورت برابری تعداد تکرار، ترتیب الفبایی ملاک قرار گیرد.

* خروجی:

فایل csv شامل ستون‌های شناسه یا نام فیلم، و ستون تگ‌های ۱ تا ۴ همراه با تعداد دفعات تکرار آن‌ها

TEXT				
movieID	tag1 (count)	tag2 (count)	tag3 (count)	tag4 (count)
1	plot (45)	funny (32)	great (28)	action (15)
...				

۳-۳- وظیفه سوم: رتبه‌بندی فیلم‌ها بر اساس برچسب (Tag-based Top Movies)

برنامه‌ای بنویسید که به ازای هر برچسب موجود، ۳ فیلم برتر را پیشنهاد دهد.

معیار برتر بودن: میانگین امتیاز فیلم (محاسبه شده در وظیفه اول) بالاتر باشد.

¹ Tasks

² Average Rating

³ Tag

✱ خروجی:

فایل csv شامل ستون‌های برچسب، و ستون‌های شناسه یا نام ۳ فیلم برتر همراه با امتیاز هر فیلم.

TEXT			
tag	movieID1 (avg)	movieID2 (avg)	movieID3 (avg)
action	318 (4.3)	64 (4.1)	150 (4.0)
comedy	595 (4.2)	1 (4.1)	239 (4.0)
...			

۳-۴- وظیفه چهارم: سیستم پیشنهادگر شخصی‌سازی شده (Personalized Recommender System)

این وظیفه شامل دو بخش پردازشی است که باید در نهایت یک خروجی یکپارچه برای هر کاربر تولید کند:

۱. بخش الف (استخراج پروفایل کاربر):

با بررسی فیلم‌هایی که هر کاربر تماشا کرده (امتیاز داده است) و تطبیق آن با ژانر فیلم‌ها، ۲ ژانر محبوب هر کاربر را پیدا کنید. (ژانر محبوب، ژانری است که کاربر تعداد فیلم بیشتری از آن دسته‌بندی تماشا کرده باشد).

✱ خروجی بخش الف:

فایل csv شامل ستون شناسه کاربر و ستون‌های ۲ ژانر محبوب هر کاربر همراه با دفعات تکرار هر ژانر

TEXT		
userID	genre1 (count)	genre2 (count)
1	Drama (25)	Comedy (18)
2	Action (12)	Thriller (10)
...		

۲. بخش ب (تولید پیشنهاد):

برای هر کاربر، یک لیست Top-5 از فیلم‌هایی که تاکنون ندیده است (در لیست امتیازات او وجود ندارد) پیشنهاد دهید. معیار انتخاب و رتبه‌بندی ۵ فیلم برتر:

❖ فیلم حتماً حداقل یکی از ۲ ژانر محبوب کاربر را داشته باشد.

❖ فیلم‌هایی که هر دو ژانر محبوب کاربر را همزمان دارند در اولویت بالاتری (Top) قرار گیرند.

در شرایط برابر ژانرها، فیلمی پیشنهاد شود که میانگین امتیاز بالاتری (خروجی وظیفه ۱) در کل سیستم داشته باشد.

✱ خروجی بخش ب:

فایل csv شامل ستون شناسه کاربر و ستون‌های شناسه یا نام ۵ فیلم پیشنهادی

TEXT				
userID	movieID1 (score)	movieID2 (score)	...	movieID5 (score)
1	123 (8.5)	456 (8.2)	...	789 (7.9)
...				

۴- الزامات فنی و نکات پیاده‌سازی

در حال حاضر (۲۵ فروردین) سایت‌های <https://www.python.org> و <https://pypi.org> در دسترس هستند و با استفاده از دستور زیر می‌توانید mrjob را نصب و استفاده کنید.

```
pip install mrjob
```

در صورتی که برای نصب پکیج‌ها به مشکل برخورد کردید، می‌توانید از mirrorهای داخلی برای نصب کتابخانه‌های پایتون استفاده کنید. با استفاده از مرور رانفلر، شما می‌توانید به راحتی و با سرعت بالا، به پکیج‌های مورد نیاز برای راه‌اندازی پروژه دسترسی داشته باشید و پکیج‌های استفاده شده در پروژه را دانلود و پروژه خود را راه‌اندازی کنید.

source host:

<https://mirror-pypi.runflare.com>

source address:

<https://mirror-pypi.runflare.com/simple/>

طبق الگوی زیر می‌توانید به نصب پکیج اقدام کنید:

```
pip install --trusted-host [host] -i [address] package-name
```

نمونه کد زیر، برای نصب پکیج mrjob با استفاده از مخزن جایگزین است:

```
pip install --trusted-host https://mirror-pypi.runflare.com -i https://mirror-pypi.runflare.com/simple/ mrjob
```

* به جای mrjob می‌توانید نام پکیج خود را جایگزین کنید.^۱

۵- نحوه ارسال تمرین

دانشجویان موظفاند فایل‌های زیر را در قالب یک فایل فشرده (ZIP) با فرمت نام‌گذاری HW02-BD-StuID-

MapReduce.zip در سامانه کوئرا بارگذاری نمایند (در صورتی که حجم فایل از ۲۰ مگابایت بیشتر شد شما می‌توانید در سایت‌های آپلود داخلی مدت‌دار فایل خود را آپلود کرده و لینک دسترسی به آن را در کوئرا بارگذاری کنید).

۱. کدهای پایتون (py files) به تفکیک هر وظیفه.

۲. فایل‌های csv مربوط به خروجی هر وظیفه.

۳. یک فایل گزارش (PDF) شامل نحوه اجرای کدها، توضیح منطق Map و Reduce برای هر وظیفه، و اسکرین‌شات از

خروجی‌های ابتدایی (۱۰ مورد اول) روی مجموعه داده

^۱ <https://parswebserver.com/mirror-storages-for-pip/>

نکته: در صورت عدم دسترسی به سامانه کوئرا می‌توانید فایل‌های خود یا لینک دسترسی به آن‌ها را به چت شخصی طراح
سوالات ارسال کنید:

آیدی بله، ایتا و تلگرام: @behnoosh_bhy

مهلت ارسال تمرین: ۴ اردیبهشت ۱۴۰۵

۶- پیشنهادها

هوش مصنوعی‌های کاربردی:

- <https://gapgpt.app/>
- <https://app.doona.ai>
- <https://chat.zharph.com/>

سایت بارگذاری مدت‌دار فایل:

- <https://my.files.ir/>
- <https://cloud.ui.ac.ir/>

کار با mirrorهای داخلی:

- <https://parswebserver.com/mirror-storages-for-pip/>

موفق و پیروز باشید 🍀