



دانشگاه اصفهان

درس پردازش سیستم‌های داده حجیم

تمرین عملی فصل Spark

استاد: دکتر محمدعلی نعمت بخش

طراح تمرین: علی معینیان

سلام به همه دانشجویان عزیز 🖐️

۱- معرفی مجموعه داده

دیتاست آماده شده به نام sales_data_1M.csv شامل یک میلیون رکورد یک آنلاین‌شاپ است که در سال ۲۰۲۳ ثبت شده است. [[لینک دانلود دیتاست](#)]

دیتاست داده شده را دانلود و بررسی کنید و با مقادیر موجود و فرمت های داده‌های داده شده توجه کنید.

۲- شرح وظایف

مرحله یک: راه اندازی پروژه

پیشنهاد ما این است که ساختار پوشه تمرین شما به شکل استاندارد باشد :

```
spark-assignment/  
├─ docker-compose.yml  
├─ data/  
│   └─ sales_data.csv  
└─ jobs/  
    └─ analysis.py
```

یک فایل docker-compose بنویسید که شامل یک کلاستر دارای یک Master و سه Worker باشد. (مشابه این فایل به نام docker-compose.yml در اختیار شما قرار دارد اما باید منطبق با پروژه، تغییراتی را در صورت نیاز وارد کنید، یا خودتان از صفر این فایل را بنویسید. [[لینک دانلود](#)])

پس از اجرای فایل، آیا Spark Master Web UI خود را در Localhost با پورت تعیین شده (مثلا localhost:8080) در docker compose مشاهده می‌کنید؟ وضعیت workerها را می‌توانید مشاهده کنید؟ در گزارش خود بنویسید که هر Worker چند Core و چه مقدار Memory به خود اختصاص داده است.

اسکرین شات از وضعیت Alive بودن Workerها الزامی است.

مرحله دو: ایجاد Spark Session

ابتدا باید با استفاده از jobs/analysis.py Cluster را بسازید. کد زیر به عنوان نمونه به شما داده شده است :

```
from pyspark.sql import SparkSession
from pyspark.sql import functions as F
from pyspark.sql.types import *

spark = SparkSession.builder \
    .appName("EcommerceSalesAnalysis") \
    .master("???") \
    .getOrCreate()
```

حال باید دیتاهای داده شده را بارگزاری کنید. می‌توانید از کد زیر ایده بگیرید:

```
df = spark.read \
    .option("???", ???) \
    .csv("/opt/spark/data/sales_data.csv")
```

دقت داشته باشید که در کد بالا، صرفاً یک مثال و راهنمایی آورده شده است و اگر منطبق با همین کد بخواهید پیش بروید، باید پوشه data لوکال شما به این مسیر در تمامی containerها (هم Master و هم سه Worker) Map یا Mount شود. اگر فایل روی Master باشد، Workerها هنگام پردازش توزیع شده خطا خواهند داد.

پس در پایان این مرحله شما باید SparkSession را به Master متصل کنید، فایل دیتاست را بخوانید و اگر این کار به درستی انجام شده باشد باید df.count() تعداد رکوردها را در خروجی نمایش دهید. همچنین با استفاده از df.printSchema() باید اسکیمای دیتاست را چاپ کنید.

مرحله ۳: تمیزسازی داده‌ها

داده‌های خام معمولاً نیاز به پردازش دارند. ستون‌های عددی را بررسی کنید از نظر فرمت و چک کنید که فرمت تاریخ، یک فرمت استاندارد باشد.

یک ستون جدید ایجاد کنید به نام sale_month که ماه فروش را از sale_date استخراج کند.

داده‌ها را مجدد مورد بررسی قرار دهید، آیا Missing Information داریم؟ آیا داده‌های منفی غیرمنطقی داریم؟

اصلاً آیا total_price به درستی محاسبه شده است؟

در صورت وجود ایراد در هر کدام از ستون‌های داده شده سعی کنید آن را حل کنید.

در صورتی که با ابهاماتی در دیتاست مواجه شدید، سعی کنید آن را بدون حذف کردن داده‌ها حل کنید و رویکرد حذف داده را برای زمانی اختصاص دهید که هیچ راهی نمانده باشد!

مرحله ۴: تحلیل داده با Data Frame API

درآمد کل را به ازای هر category محاسبه کنید و نتیجه را به ترتیب نزولی مرتب کنید.

۴ شهری که بیشترین تعداد سفارش را داشته است کدام بوده؟

میانگین customer_rating را به ازای هر category محاسبه کنید و نتیجه را نمایش دهید.

درآمد کل را به تفکیک ماه محاسبه کنید و نمایش دهید.

سفارش‌هایی را فیلتر کنید که discount_percent آنها بیشتر از ۱۵ باشد و customer_rating آن نیز بیشتر یا مساوی ۴ باشد و سپس تعداد این سفارش‌ها را به تفکیک category نمایش دهید.

مرحله ۵: Spark SQL

در این مرحله برای تحلیل داده از SQL استفاده می‌کنیم. برای این کار ابتدا باید DataFrame را به عنوان Temp View ثبت کنید. تکه کد زیر برای این کار به شما کمک خواهد کرد:

```
df_clean.createOrReplaceTempView("sales")
result = spark.sql("SELECT * FROM sales LIMIT 5")
result.show()
```

حال باید کوئری بنویسید که در هر category پرفروش‌ترین محصول را پیدا کند.

شهرهایی که total_price آن‌ها بیشتر از ۵۰۰ بوده است را پیدا کنید و تعداد سفارشات آن‌ها را نمایش دهید و نتیجه را به صورت نزولی مرتب کنید.

مرحله ۶: درک عمیق کلاستر و RDD

ابتدا باید df_clean که همان دیتافریم داده‌ی تمیز شده‌ی شما بوده است را به RDD تبدیل کنید و اولین element آن را چاپ کنید.

با دستور rdd.getNumPartitions() بررسی کنید که اسپارک، داده‌های شما را به چند بخش تقسیم کرده است؟

با استفاده از reduceByKey() مجموع total_price را به ازای هر category محاسبه کنید.

در حین اجرای این مرحله به Web UI بروید و اسکرین‌شاتی بگیرید که نشان دهد تسک‌ها چگونه بین ۳ Worker تقسیم شده. آیا هر سه Worker در حال کار هستند؟

نمره مثبت:

یک پردازش سنگین، مانند یک count روی دیتا یا هر ایده‌ای که خودتان دارید را اجرا کنید و در حالی که کد شما در حال اجراست، یکی از کانتینرهای worker را به صورت دستی stop کنید. در گزارش نهایی توضیح دهید چه اتفاقی برای job افتاد؟ آیا برنامه crash کرد؟

مرحله ۷: ذخیره نتایج

تمام خروجی‌های خود را از هر نوعی که هستند (شکل‌ها، فایل‌های CSV و ...) ذخیره کنید و به همراه داکيومنت مناسب ارسال نمایید.

۳- الزامات فنی و نکات پیاده‌سازی

به دلیل عدم دسترسی به اینترنت بین‌الملل برای دانلود و استفاده از imageهای spark نسخه‌ی پایدار bitnamilegacy/spark:3.5.4 جهت استفاده سریع‌تر شما در لینک زیر قابل دسترسی است.

۳-۱- دانلود نسخه پایدار 3.5.4

ابتدا نسخه‌ی 3.5.4 را از [لینک](#) دانلود کنید.

۳-۲- انتقال به مسیر مناسب

فایل spark3.5.4-image.tar را به مسیر مناسبی انتقال دهید.


۳-۳- نصب spark image

با استفاده از ترمینال Docker Desktop به دایرکتوری‌ای که فایل spark3.5.4-image.tar در آن قرار دارد بروید و دستور زیر را اجرا کنید:

```
docker load -i spark3.5.4-image.tar
```

۳-۴- بررسی نصب

نسخه bitnamilegacy/spark:3.5.4 باید به لیست imageها در منو images اضافه شده باشد.



نکته!

برای تکمیل تمرین خود نیاز است در فایل yml هنگام تعریف containerها اسم دقیق این image را وارد کنید.

```
Welcome  docker-compose.yml X
docker-compose.yml
1  version: '3'
   Run All Services
2  services:
   Run Service
3  spark-master:
4  image: bitnamilegacy/spark:3.5.4
5  environment:
6    - SPARK_MODE=master
7    - SPARK_RPC_AUTHENTICATION_ENABLED=no
8    - SPARK_RPC_ENCRYPTION_ENABLED=no
9    - SPARK_LOCAL_STORAGE_ENCRYPTION_ENABLED=no
10   - SPARK_SSL_ENABLED=no
11  ports:
12    - '8080:8080'
13    - '7077:7077'
14
   Run Service
15  spark-worker-1:
16  image: bitnamilegacy/spark:3.5.4
17  environment:
18    - SPARK_MODE=worker
```

۴- نحوه ارسال تمرین

دانشجویان موظفاند فایل‌های پاسخ خود را در قالب یک فایل فشرده (ZIP) با فرمت نام‌گذاری HW04-BD-*StuID*-spark.zip در سامانه کوئرا بارگذاری نمایند (در صورتی که حجم فایل از ۲۰ مگابایت بیشتر شد شما می‌توانید در سایت‌های آپلود داخلی مدت‌دار فایل خود را آپلود کرده و لینک دسترسی به آن را در کوئرا بارگذاری کنید).

۵- پیشنهادها

هوش مصنوعی‌های کاربردی:

- <https://gapgpt.app/>
- <https://app.doona.ai>
- <https://chat.zharph.com/>
- دیپ سیک هم که سایت اصلیش بازه 😊

سایت بارگذاری مدت‌دار فایل:

- <https://my.files.ir/>
- <https://cloud.ui.ac.ir/>

کار با mirror های داخلی:

• <https://parswebserver.com/mirror-storages-for-pip/>

موفق و پیروز باشید 🍀