



دانشگاه اصفهان

درس پردازش سیستم‌های داده حجیم

تکلیف فصل Spark MLlib: پیش‌بینی هزینه سفر تاکسی با Spark MLlib

استاد: دکتر محمدعلی نعمت بخش

طراح تمرین: بهنوش بهیانی

مهلت ارسال: ۱۴۰۵/۰۳/۲۹

۱- مقدمه

در دنیای واقعی مهندسی داده، ذخیره و پردازش داده به‌تنهایی کافی نیست. تیم‌های داده باید بتوانند از داده‌های خام، مدل‌های هوشمندی بسازند که به تصمیم‌گیری کمک کنند. یکی از پرکاربردترین این مدل‌ها، مدل‌های پیش‌بینی عددی یا Regression هستند.

در این تکلیف با داده‌های واقعی سفرهای تاکسی شهر نیویورک^۱ کار می‌کنید. این داده‌ها توسط کمیسیون تاکسی و لیموزین شهر نیویورک جمع‌آوری و به‌صورت عمومی منتشر می‌شوند و شامل میلیون‌ها رکورد سفر تاکسی هستند. هدف این تمرین ساخت یک pipeline کامل از بارگذاری داده خام تا آموزش و ارزیابی مدل ML در بستر Apache Spark است. این تکلیف بر روی MLlib Spark تمرکز دارد؛ کتابخانه‌ای که برای پردازش موازی داده‌های بزرگ در مقیاس واقعی طراحی شده است. شما نه تنها یاد می‌گیرید چگونه مدل بسازید، بلکه یاد می‌گیرید این مدل را در یک گردش کار مهندسی داده واقعی ادغام کنید.

۲- اهداف اصلی تمرین

پس از تکمیل این تکلیف، انتظار می‌رود با مفاهیم زیر آشنا شده باشید:

- کار با MLlib Spark برای ساخت مدل‌های رگرسیون در مقیاس بزرگ
- Feature Engineering روی داده‌های زمانی و جغرافیایی
- ساخت Pipeline کامل ML از ورود داده تا استقرار مدل
- ارزیابی کمی مدل با متریک‌های استاندارد (R^2 , MAE, RMSE)
- ذخیره و بارگذاری مدل آموزش‌دیده برای استقرار
- درک مفهومی تفاوت بین مدل‌های مختلف رگرسیون

۳- معرفی مجموعه داده

دیتاست این پروژه، داده‌های رسمی سفرهای تاکسی زرد (Yellow Taxi) شهر نیویورک است که توسط NYC TLC منتشر می‌شود. این داده‌ها از آدرس زیر قابل دسترس هستند:

<https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>

^۱ NYC TLC Trip Record Data

برای این پروژه از داده‌های ماه ژانویه ۲۰۲۶ استفاده کنید (فایل Parquet Yellow Taxi).

- [لینک اصلی دسترسی به داده‌های ماه ژانویه ۲۰۲۶](#)

- [لینک داخلی دسترسی به داده‌های ماه ژانویه ۲۰۲۶](#)

۱-۳- ساختار داده

مجموع کل ستون‌ها ۲۲ است. ۱۱ ستون مهم از مجموعه داده در جدول ۱ به اختصار معرفی شده‌اند.

جدول ۱: معرفی ۱۱ ستون مهم از مجموعه داده

ستون	توضیح
tpep_pickup_datetime	زمان سوار شدن مسافر
tpep_dropoff_datetime	زمان پیاده شدن مسافر
passenger_count	تعداد مسافر
trip_distance	مسافت سفر (مایل)
PULocationID	شناسه منطقه سوارشدن
DOLocationID	شناسه منطقه پیاده‌شدن
RatecodeID	نوع نرخ‌گذاری سفر
payment_type	روش پرداخت
fare_amount	کرایه پایه
tip_amount	انعام
total_amount	مجموع هزینه (متغیر هدف)

۲-۳- نمونه‌گیری از داده

داده‌های ماه ژانویه سال ۲۰۲۶ حدود ۳ میلیون رکورد دارند. اجرای کل این داده روی لپ‌تاپ شخصی ممکن است بسیار کند باشد. از این رو، باید یک نمونه تصادفی مناسب از داده بردارید.

حجم پیشنهادی نمونه: ۲۰۰,۰۰۰ رکورد

این حجم برای آموزش مدل‌های ML در Spark بر روی سخت‌افزار شخصی کافی است و نتایج آماری معناداری ارائه می‌دهد.

روش نمونه‌گیری: از تابع sample() در PySpark با seed ثابت (seed=42) استفاده کنید تا نتایج قابل تکرار باشد.

😞 چرا seed ثابت در نمونه‌گیری تصادفی اهمیت دارد؟ چه اتفاقی می‌افتد اگر هر بار مدل را با seed متفاوت آموزش دهید؟

❓ با نمونه‌ی ۲۰۰,۰۰۰ رکوردی چه درصدی از داده‌های اصلی را پوشش می‌دهید؟ آیا این درصد برای تعمیم مدل کافی است؟

۴- معماری کلی پروژه

این پروژه از یک گردش کار استاندارد ML در بستر PySpark پیروی می‌کند. داده خام بارگذاری و نمونه‌گیری می‌شود، سپس پاکسازی و Feature Engineering انجام می‌گیرد، و در نهایت مدل آموزش داده، ارزیابی و ذخیره می‌شود.

1	2	3	4	5	6
Load & Prepare	Feature Eng.	Build Pipeline	Train Model	Evaluate	Save & Deploy

۵- فازهای پروژه

۵-۱- فاز اول: بارگذاری و آماده‌سازی داده^۱

در این مرحله داده خام را از فایل Parquet بارگذاری کرده، نمونه‌گیری انجام دهید و داده را برای مراحل بعدی آماده کنید.

الزامات این فاز:

- بارگذاری فایل Parquet با PySpark و نمایش schema اولیه
- نمونه‌گیری تصادفی با seed=42 و حجم ۲۰۰,۰۰۰ رکورد
- نمایش آمار پایه داده با describe() برای شناخت توزیع ستون‌ها
- اجرای printSchema() و show(5) برای تأیید صحت بارگذاری

? فرمت Parquet چه مزایایی نسبت به CSV برای پردازش با Spark دارد؟ به مفهوم Columnar Storage اشاره کنید.

۵-۱-۱- پاکسازی داده

رکوردهای زیر را حذف کنید و برای هر دسته تعداد رکوردهای حذف‌شده را گزارش دهید:

- total_amount کمتر یا مساوی صفر یا منفی (سفرهای رایگان یا خطای ثبت)
- trip_distance کمتر یا مساوی صفر
- passenger_count کمتر یا مساوی صفر یا بیشتر از ۱۰
- زمان سفر (تفاوت pickup و dropoff) منفی یا بیشتر از ۳ ساعت
- مقادیر پرت^۲ total_amount : بیشتر از صدک ۹۹.۵ ام
- رکوردهای تکراری بر اساس ترکیب (pickup_datetime, PULocationID, DOLocationID)

۵-۲- فاز دوم: مهندسی ویژگی^۳

Feature Engineering قلب هر پروژه ML است. در این مرحله باید از داده‌های خام، ویژگی‌هایی بسازید که به مدل کمک کنند الگوهای پنهان را کشف کند.

۵-۲-۱- ساخت ویژگی‌های جدید (امتیازی)

^۱ Load & Prepare

^۲ Outlier

^۳ Feature Engineering

ویژگی‌های زیر را ایجاد کنید:

نام ویژگی	توضیح و نحوه محاسبه
trip_duration_min	مدت سفر به دقیقه: تفاوت pickup و dropoff
pickup_hour	ساعت شروع سفر (۰ تا ۲۳) از pickup_datetime
pickup_day_of_week	روز هفته (۰=دوشنبه، ۶=یکشنبه)
is_weekend	متغیر باینری: ۱ اگر آخر هفته باشد، ۰ در غیر این صورت
is_rush_hour	متغیر باینری: ۱ اگر ساعت ۷-۹ یا ۱۷-۱۹ باشد
is_night	متغیر باینری: ۱ اگر ساعت ۲۲-۶ باشد
speed_mph	سرعت میانگین: (trip_distance / (trip_duration_min / ۶۰))
same_location	۱ اگر PULocationID == DOLocationID باشد

? چرا ویژگی is_rush_hour ممکن است برای پیش‌بینی هزینه مهم باشد؟ چه رابطه‌ای بین ترافیک و هزینه سفر تاکسی وجود دارد؟
? اگر بخواهید مکان جغرافیایی را به‌صورت عددی در مدل وارد کنید، چه روش‌هایی وجود دارد؟ استفاده مستقیم از PULocationID و DOLocationID چه مشکلی دارد؟

۵-۲-۲- انتخاب ویژگی‌ها بر اساس همبستگی^۱

پس از ساخت ویژگی‌های جدید، باید ویژگی‌هایی را انتخاب کنیم که بیشترین رابطه را با متغیر هدف (total_amount) دارند.

مراحل انجام این کار:

- محاسبه ماتریس همبستگی
 - از ضریب همبستگی Pearson استفاده کنید و همبستگی هر ویژگی با متغیر هدف را محاسبه کنید.
- انتخاب ویژگی‌های برتر
 - ویژگی‌هایی که مقدار مطلق همبستگی ($|correlation|$) آن‌ها با هدف بالاتر از یک آستانه (۰.۱۵) است را نگه دارید. یا Top N ویژگی با بیشترین همبستگی را انتخاب کنید (مثلاً Top 10).
- بررسی Multicollinearity
 - همبستگی بین خود ویژگی‌ها را چک کنید. اگر دو ویژگی همبستگی خیلی بالا با هم داشته باشند (مثلاً $0.9 <$)، یکی از آن‌ها را حذف کنید تا مدل دچار ناپایداری نشود. گزارش کنید کدام ویژگی‌ها همبستگی بالایی با همدیگر دارند.

۵-۲-۳- ذخیره داده

داده جدید (رکوردهای پاکسازی شده + ویژگی‌های انتخاب‌شده بر اساس همبستگی + ستون هدف) را به‌صورت یک DataFrame ذخیره کنید (Parquet یا CSV). این DataFrame پایه آموزش مدل خواهد بود.

¹ Correlation-based Feature Selection

۵-۳- فاز سوم: ساخت Pipeline یادگیری ماشین^۱

در MLlib Spark، یک ML Pipeline مجموعه‌ای از مراحل^۲ است که هر Stage یا یک Transformer است (داده را تبدیل می‌کند) یا یک Estimator (مدل را آموزش می‌دهد). این رویکرد کد را تمیزتر، قابل تکرار و آماده‌ی استقرار می‌کند.

مراحل Pipeline:

- VectorAssembler: ترکیب ویژگی‌های عددی در یک ستون features
- StandardScaler: نرمال‌سازی ویژگی‌ها برای بهبود همگرایی مدل
- مدل رگرسیون (در فاز بعدی انتخاب می‌شود)

تقسیم داده:

داده پاک‌شده را به دو بخش تقسیم کنید: ۸۰٪ برای آموزش (train) و ۲۰٪ برای آزمایش (test). از randomSplit با seed=42 استفاده کنید.

۵-۴- فاز چهارم: آموزش مدل^۳

در این مرحله باید حداقل ۲ مدل رگرسیون مختلف از MLlib Spark آموزش دهید. هدف نه‌تنها ساخت مدل بلکه درک تفاوت رفتاری آن‌ها در این مسئله است.

مدل‌های الزامی:

مدل	توضیح مختصر
Linear Regression	مدل خطی ساده؛ پایه مقایسه (Baseline)
Gradient Boosted Trees (GBT)	تقویت تدریجی درختان؛ معمولاً دقیق‌ترین مدل

پارامترهای پیشنهادی برای شروع:

- Linear Regression: maxIter=100, regParam=0.01
- GBT: maxIter=50, maxDepth=8, stepSize=0.1

? پارامتر regParam در Linear Regression چه کاری انجام می‌دهد؟ چه اتفاقی می‌افتد اگر این مقدار خیلی بزرگ یا خیلی کوچک باشد؟

۵-۵- فاز پنجم: ارزیابی و تنظیم مدل^۴

آموزش مدل بدون ارزیابی دقیق بی‌معناست. در این فاز عملکرد مدل‌ها را با متریک‌های استاندارد بسنجید، نتایج را مقایسه کنید و بهترین مدل را بهینه‌سازی کنید.

۵-۵-۱- متریک‌های ارزیابی

برای هر دو مدل روی داده Test، متریک‌های زیر را محاسبه کنید:

^۱ Build Pipeline

^۲ Stage

^۳ Train Model

^۴ Evaluate & Tune

متریک	تعریف و تفسیر
RMSE (Root Mean Squared Error)	ریشه میانگین مربعات خطا؛ به واحد متغیر هدف (دلار) است
MAE (Mean Absolute Error)	میانگین قدرمطلق خطا؛ کمتر تحت تأثیر outlier
R ² (Coefficient of Determination)	ضریب تعیین؛ ۱=بی نقص، ۰=بد از میانگین ساده

نتایج هر دو مدل را در یک جدول مقایسه‌ای در نوت‌بوک نمایش دهید.

۵-۵-۲- تنظیم هایپرپارامتر با Cross-Validation (امتیازی)

بهترین مدل (بر اساس RMSE روی مجموعه تست) را با استفاده از CrossValidator یا TrainValidationSplit در MLlib بهینه کنید. یک پارامتر مهم را انتخاب کنید و برای آن ۳ مقدار مختلف تعریف کنید.

۵-۵-۳- تحلیل اهمیت ویژگی‌ها^۱

برای مدل GBT، اهمیت ویژگی‌ها را استخراج کرده و در یک نمودار میله‌ای نمایش دهید.

؟ تفاوت RMSE و MAE چیست؟ در چه شرایطی MAE گزینه بهتری برای ارزیابی است؟

؟ کدام ویژگی بیشترین تأثیر را در پیش‌بینی هزینه دارد؟ آیا این نتیجه با انتظار شما از دنیای واقعی مطابقت دارد؟

۵-۶- فاز ششم: ذخیره و استقرار مدل^۲

آموزش مدل پایان کار نیست. در دنیای واقعی مدل باید ذخیره شود تا بتوان بدون آموزش مجدد از آن استفاده کرد. این فاز نحوه استقرار مدل در یک گردش کار ML واقعی را شبیه‌سازی می‌کند.

الزامات این فاز:

- ذخیره بهترین Pipeline آموزش‌دیده
- بارگذاری مدل ذخیره‌شده در یک session جدید Spark (یا سلول جدید نوت‌بوک)
- اجرای پیش‌بینی روی ۲ نمونه دلخواه از test set با مدل بارگذاری‌شده
- ذخیره نتایج پیش‌بینی به صورت فایل Parquet

؟ چرا باید کل Pipeline (شامل مراحل پیش‌پردازش) را ذخیره کنیم و نه فقط مدل نهایی را؟

؟ در یک سیستم واقعی، مدل جدید چه زمانی باید جایگزین مدل قدیمی شود؟ چه معیارهایی برای این تصمیم وجود دارد؟

۶- خروجی‌های نهایی پروژه

دانشجویان موظف‌اند فایل‌های زیر را در قالب یک فایل فشرده (ZIP) با فرمت نام‌گذاری HW06-BD-StuID-SparkMLlib.zip در سامانه کوئرا بارگذاری نمایند (در صورتی که حجم فایل از ۲۰ مگابایت بیشتر شد شما می‌توانید در سایت‌های آپلود داخلی مدت‌دار فایل خود را آپلود کرده و لینک دسترسی به آن را در کوئرا بارگذاری کنید).

¹ Feature Importance

² Save & Deploy

آیتم	توضیح
Jupyter Notebook	نوت‌بوک کامل و مستند با تمام فازها، خروجی سلول‌ها حفظ شده باشد
جدول مقایسه مدل‌ها	RMSE، MAE، R^2 برای ۲ مدل در قالب عکس یا فایل CSV
نمودار Feature Importance	بارچارت ویژگی‌های مهم مدل بهینه
مدل ذخیره‌شده	فایل‌های Pipeline ذخیره‌شده در پوشه /models
فایل نتایج پیش‌بینی	پیش‌بینی‌های test set ذخیره‌شده به فرمت Parquet
فایل گزارش PDF	گزارش مستندسازی - جواب سوالات هر بخش + توضیحات و خروجی‌های مربوط به هر فاز

نکته: در صورت عدم دسترسی به سامانه کوئرا می‌توانید فایل‌های خود یا لینک دسترسی به آن‌ها را به چت شخصی طراح سوالات ارسال کنید:

آیدی بله، ایتا و تلگرام: @behnoosh_bhy

مهلت ارسال تمرین: ۲۹ خرداد ۱۴۰۵

۷- پیشنهادها (در صورت اختلال در اینترنت)

هوش مصنوعی‌های کاربردی:

- <https://gapgpt.app/>
- <https://app.doona.ai>
- <https://chat.zharph.com/>

سایت بارگذاری مدت‌دار فایل:

- <https://my.files.ir/>
- <https://cloud.ui.ac.ir/>

کار با mirrorهای داخلی:

- <https://parswebserver.com/mirror-storages-for-pip/>

موفق و پیروز باشید 🍀